

推理赛题与规则

T2-1-1 模型适配

1. 基本要求

指定模型：文心一言4.5VL（ERNIE-4.5-VL-28B-A3B）

模型Hugging Face地址：

- <https://huggingface.co/baidu/ERNIE-4.5-VL-28B-A3B-Thinking>

2. 必须支持的平台

- 英伟达（NVIDIA）：必选
- 可选平台：天数、摩尔、沐曦

3. 核心功能实现清单

选手需在InfiniCore/InfiniLM框架内完成以下模块适配：

- (1) Vision Tower（视觉编码器）
- (2) MoE（混合专家）模块
- (3) 多模态适配器（Adapter）
- (4) 单卡与分布式推理

4. 推理正确性验证

选手需提交推理正确性测试脚本。测试内容应覆盖以下三种输入模态的正确性：

编号	输入类型	说明
1	文本→文本	纯文本对话，验证基础语言理解能力
2	图像+文本→文本	图文多模态理解
3	视频+文本→文本	视频内容理解与描述

验证方式：

- 与Hugging Face官方推理示例进行对比（使用transformers库加载官方模型作为参照）
- 对比指标：输出token序列的完全一致性，或在相同输入下语义等价性

- 测试脚本可包含第三方推理引擎依赖仅作为测试参照，提交的适配代码本身不能依赖第三方框架功能
- 辅助测试工具：test_benchmark精度测试脚本

5. 评判标准

维度	权重	说明
单轮推理正确	必要要求	图文→文、文→文、视频+文→文三类输入均正确；不影响框架原有功能；在InfiniLM不涉及硬件平台特判；不修改且不使用legacy llama代码
代码整洁度	必要要求	正确利用框架内模块化设计，结构合理；代码整洁且不遗留纯调试代码(比如过多的log)；结赛时与主分支无conflict
适配平台数量	-	在英伟达基础上，完成任意国产平台的适配，多适配有加分
性能	-	推理速度、内存占用等表现
服务能力	-	推理服务的可用性和稳定性

6. 奖金分配（总奖金池：¥20,000）

获奖队伍数	分配比例
1队	100%（¥20,000）
2队	8:2（¥16,000 / ¥4,000）
3队	7:2:1（¥14,000 / ¥4,000 / ¥2,000）

性能优化

T2-1-2 服务能力优化

测试模型：8B模型、70B模型

目标：多并发、长文本服务场景中，输出吞吐和总吞吐量提升；小规模性能无明显下降，有提升可加分。

测试矩阵：

模型	并发数	输入长度 (tokens)	输出长度 (tokens)
8B	1, 4	32, 256, 4096	256, 1024, 4096
8B	16, 64	32, 256	256, 1024, 4096
70B	1, 4, 16	32, 256	256, 1024, 2048

参考服务指令

代码块

```
1 python python/infinilm/server/inference_server.py --device nvidia --
  model=/<path-to>/9g_8b_thinking_llama/ --temperature 1.0 --top-p 0.8 --top-k 1
  --port 8102 --tp 1 --max-new-tokens 4096 --num-blocks 6144 --max-batch-size
  <max_con> --enable-graph --enable-paged-attn --attn flash-attn --ignore-eos
```

参考测试脚本

代码块

```
1 # 客户端
2 unset http_proxy https_proxy all_proxy ALL_PROXY
3 batch_size_list=(1 ) # (1 4 16 64)
4 random_input_len_list=(32 256 4096 ) # (32 256 4096)
5 random_output_len_list=(256 1024 2048 4096 ) # ( 256 1024 2048 4096 )
6
7 # 外层循环: 遍历 max-batch_size_list
8 for batch_size in "${batch_size_list[@]}"; do
9     # 中层循环: 遍历 random-input-len
10    for random_input_len in "${random_input_len_list[@]}"; do
11        # 内层循环: 遍历 random-output-len
12        for random_output_len in "${random_output_len_list[@]}"; do
13            sleep 1
14            seed=$(date +%s)
15
16            # 压力测试参数
17            num_prompts=$(( $batch_size * 1 ))
18            request_rate=inf # 或用 1000000.0 但推荐 inf 表示爆发模式
19
20            # 定义输出文件名变量
21
22            output_file="infinilm_client_A100_model=9g_8b_thinking_llama_batch_size=${batch
  _size}_random_input_len=${random_input_len}_random_output_len=${random_output_l
  en}_seed=${seed}.json"
```

```

23          # 打印当前组合，同时输出到屏幕并追加到独立文件
24          echo "Running with batch_size=${batch_size},
random_input_len=${random_input_len}, random_output_len=${random_output_len}"
/ tee -a "$output_file"

25
26          # 执行基准测试命令，输出追加到同一个独立文件
27          vllm bench serve \
28              --backend openai-chat \
29              --model 9g_8b_thinking \
30              --tokenizer /data-
aisoft/mechdancer/models/9g_8b_thinking_llama \
31              --endpoint /v1/chat/completions \
32              --request-rate "$request_rate" \
33              --port 8102 \
34              --seed "$seed" \
35              --num-prompts "$num_prompts" \
36              --max-concurrency "$batch_size" \
37              --random-input-len "$random_input_len" \
38              --extra-body "{\"max_tokens\": ${random_output_len}}" >>
"$output_file" 2>&1

39
40          done
41      done
42  done

```

奖金

奖项	名额	奖金
一等奖	1名	¥12,500
二等奖	1名	¥5,000
三等奖	1名	¥2,500

T2-1-3 Qwen3-MoE优化

模型地址：<https://huggingface.co/Qwen/Qwen3-30B-A3B-Thinking-2507>

适配要求：

- 测试风格参考长文本优化赛题

奖金

奖项	名额	奖金
一等奖	1名	¥12,500
二等奖	1名	¥5,000
三等奖	1名	¥2,500

提交要求

1. 代码：包含InfiniCore算子和InfiniLM模型适配的完整可运行代码
2. 测试脚本：推理正确性验证脚本(仅适用于模型适配)，执行方式清晰说明
3. PR内容需尽量符合CONTRIBUTING.md及pr模板要求
4. 赛题报告（必须包含）：
 - 实现的功能概述
 - 使用的技术方案和参考资料
 - 测试脚本在各平台的运行方式及运行效果截图
 - 未实现或未适配部分的说明
 - 赛题要求之外的额外功能说明（如有）